

Documentation

L'objectif principal :

L'entreprise **Ooredoo** veut répondre à une question très importante :

"Combien d'offres allons-nous vendre demain, la semaine prochaine ou le mois prochain ?"

À partir des anciennes ventes, le modèle devra prévoir les ventes futures. => c'est le **Forecasting**

Décomposition du sujet :

1. Collecter les données : Collecter et étudier les données générées par les applications de ventes.

2. Étudier les données : Il faut réaliser une **analyse exploratoire des données (EDA)** (examiner, nettoyer et visualiser les données afin de comprendre leurs caractéristiques avant de construire un modèle de forecasting) .

3. Construire un modèle de prévision :

Modèles classiques

- **ARIMA:** prédit les valeurs futures en utilisant les tendances et les valeurs passées d'une série temporelle. ✓
- **SARIMA:** version d'ARIMA qui prend aussi en compte la saisonnalité (par exemple, des ventes qui augmentent chaque été).
- **Holt-Winters :** prédit les données en tenant compte du niveau, de la tendance et de la saisonnalité
- **Prophet :** modèle développé par Meta, simple à utiliser et efficace pour les données avec tendances et saisonnalité. ✓

Modèles Machine Learning

- **Random Forest :** utilise plusieurs arbres de décision pour apprendre les relations dans les données et faire des prévisions.
- **XGBoost :** construit des arbres de décision de manière progressive pour corriger les erreurs et améliorer la précision ✓
- **LightGBM:** version rapide et optimisée de XGBoost, adaptée aux grands volumes de données

Deep Learning

- **LSTM**: réseau de neurones capable de mémoriser les informations importantes sur une longue période . ✓
- **GRU**: version plus simple et plus rapide du LSTM, avec des performances souvent similaires.
- **Transformer** : modèle basé sur un mécanisme d'attention qui identifie les informations les plus importantes dans les données pour réaliser des prévisions précises, notamment sur de longues séries temporelles .

IA générative :

Aujourd'hui, il existe des modèles génératifs capables de produire des prévisions, comme certains modèles basés sur des Transformers adaptés aux séries temporelles .

Voici quelques exemples connus :

TimesFM (Google Research) : un modèle de fondation développé par Google pour la prévision de séries temporelles. ✓

Chronos (Amazon) : un modèle basé sur les Transformers, conçu pour générer des prévisions de séries temporelles. ✓

Moirai (Salesforce) : un modèle de fondation (*foundation model*) pour les séries temporelles, capable de s'adapter à différents domaines.

Lag-Llama : un modèle génératif open source basé sur les Transformers, spécialisé dans les séries temporelles.

4. Entraîner le modèle :

Le modèle apprend grâce aux anciennes ventes.

5. Validation :

la **validation** consiste à vérifier si le modèle est capable de faire de bonnes prédictions sur des données qu'il **n'a jamais vues**.

On sépare les données :

- 80 % pour l'entraînement
- 20 % pour le test

Après l'entraînement du modèle sur **80 % des données historiques**, on utilise les **20 % restants**, que le modèle n'a jamais vus, pour prédire les ventes, puis on compare les **ventes prédites** aux **ventes réelles** afin de mesurer sa précision et choisir le modèle le plus performant.

6. Évaluer les performances :

On calcule des métriques.

Par exemple :

- **MAE**: calcule la moyenne des écarts absolus entre les valeurs réelles et les valeurs prédites. Plus le **MAE est faible**, plus les prévisions sont précises.

Exemple : si le modèle prédit 98 ventes alors que la réalité est 100, l'erreur est de 2.

- **RMSE**: mesure également l'erreur, mais **pénalise davantage les grandes erreurs**. Il est utile lorsqu'on veut éviter des prévisions très éloignées de la réalité.

Exemple : une erreur de 20 ventes aura beaucoup plus d'impact qu'une erreur de 2 ventes

- **MAPE** : exprime l'erreur en **pourcentage** par rapport aux valeurs réelles, ce qui permet d'évaluer facilement la précision du modèle.

Exemple : un **MAPE de 5 %** signifie que les prévisions du modèle s'écartent en moyenne de **5 %** des ventes réelles.

Plus ces erreurs sont faibles, meilleur est le modèle.

7. Implémenter la solution :

Une fois le meilleur modèle choisi, il faut créer une application.

Python + Streamlit

Un **LLM** est utilisé dans ton projet pour **expliquer les résultats des prévisions, répondre aux questions des utilisateurs et générer des rapports en langage simple à partir des données et des résultats des modèles de forecasting**, mais il ne sert pas à prédire directement les ventes

Le **RAG (Retrieval-Augmented Generation)** est une technique qui permet à un **LLM de répondre en utilisant à la fois ses connaissances et les données réelles de l'entreprise**, en récupérant d'abord les informations depuis une base de données ou des documents, puis en générant une réponse claire et précise basée sur ces données.

✓ **Avantages :**

- réponses basées sur des **données réelles**
- réduit les hallucinations du LLM
- permet de connecter l'IA aux bases de données de l'entreprise
- données toujours à jour sans réentraîner le modèle